

به نام خدا

تمرین عملی شماره دو

مبانی بازیابی اطلاعات و جستجو وب

۹۸۱۶۰۷۳

دانیال بیاتی

۹۸۲۳۷۹۳

محمد جواد کفایتی

استاد : دکتر هدی مشایخی

تعدادی مجموعه داده مرجع برای بازیابی قرار دارد که توسط حل تمرین یکی از آنها به گروه شما تعلق میگیرد. در مجموعه داده، تعدادی سند، تعداد پرس و جو و همچنین ارتباط اسناد با پرس و جوها مشخص شده است. برنامه ای بنویسید که بردار هر سند و هر پرس و جو را در فضای برداری با روش وزن دهی **idf-Tf** به دست آورد. سپس برای هر پرس و جو ۱۰ سند برتر مرتبط با پرس و جو را با روش شباهت کسینوسی محاسبه کنید و با مقایسه با مجموعه مرجع مقادیر صحت، یادآوری و معیار **F1** را برای هر پرس و جو و میانگین برای کل مجموعه داده را محاسبه کنید



فایل **main.py** برنامه اصلی می باشد که از دو کلاس شباهت کسینوسی و جستوجو تشکیل شده است.

برای حل این تمرین از کتابخانه **whoosh** کمک گرفته شده است که توابع استفاده شده به صورت زیر می باشند:

```
1 import math
2 from collections import Counter
3 from typing import Dict , List , Any
4 from typing import Tuple
5 from whoosh.analysis import StopFilter, StemmingAnalyzer
6 from whoosh.lang.porter import stem
7 from whoosh.lang.stopwords import stoplists
8 import heapq
```



```
1 class CosineSimilarity:
2     def __init__(self, documents: List[Tuple[str, str]]) -> None:
3         """ This function create list of vector for analyze content and scoring
4
5         Args:
6             documents (List[Tuple[str, str]]): List of document
7         """
8
9         self.doc_freqs : Dict[str, int] = Counter()
10        self.create_doc_frequency(documents)
11
12        self.idf: Dict[str, float] = {}
13        self.create_inverse_term_frequency(documents)
14
15        self.doc_vectors: Dict[int, Tuple[str, List[float]]] = {}
16        self.create_document_vectors(documents)
17
18    def create_doc_frequency(self, documents : List[Tuple[str, str]]) -> None:
19        """ This function create list of document frequency that contain word and number of
20            repeat in all documents
21
22        Args:
23            documents (List[Tuple[str, str]]): list of document
24        """
25        for _, doc in documents:
26            self.doc_freqs.update(Counter(doc.split()))
27
28    def create_inverse_term_frequency(self, documents : List[Tuple[str, str]]) -> None:
29        """ Create inverse term frequency with this formula
30            idf for specified word = log(length of all documents / number of repeats in all docs)
31
32        Args:
33            documents (List[Tuple[str, str]]): List of document
34        """
35        num_docs = len(documents)
36        for word, freq in self.doc_freqs.items():
37            self.idf[word] = math.log(num_docs / freq)
```

: CosineSimilarity کلاس

تابع **create_doc_frequency** به عنوان ورودی لیست داکيومنت های مورد نظر را گرفته و **tf** هر کلمه را محاسبه کرده و آرایه **doc_freq** را بروزرسانی می کند.

تابع

create_inverse_term_frequency به عنوان ورودی لیستی از داکيومنت ها را دریافت کرده و با پیمایش درون آرایه **docs_freqs** **idf** هر کلمه را حساب کرده و ذخیره می کند.



```
1 def create_document_vectors(self, documents: List[Tuple[str, str]]) -> None:
2     """ This functions create list of tuples that contain title and
3         inverse term frequency each word * term frequency of each word
4
5     Args:
6         documents (List[Tuple[str, str]]): List of document
7     """
8     for i, (title, doc) in enumerate(documents):
9         tf = Counter(doc.split())
10        vec = [tf[w] * self.idf[w] for w in self.doc_freqs.keys()]
11        self.doc_vectors[i] = (title, vec)
12
13
14
15 def cosine_similarity(self, query :str ="query") -> List[Tuple[str, float]]:
16     """ This func create list of the approximate amount query with each document
17
18     Args:
19         query (str, optional): A string that the user enters to measure the similarity
20
21     Returns:
22         List[Tuple[str, float]]: List of the approximate amount query with each document
23     """
24     # Removed stop words and finds the root of the rest
25     tf: Dict[str, int] = Counter(query.split())
26     q_vec: List[float] = [tf[w] * self.idf[w] if w in tf else 0 for w in self.doc_freqs.keys()]
27     sims: List[Tuple[str, float]] = []
28     for _, (title, d_vec) in self.doc_vectors.items():
29         dot_product: float = sum([a*b for a,b in zip(d_vec, q_vec)])
30         norm_d: float = math.sqrt(sum([a*a for a in d_vec]))
31         norm_q: float = math.sqrt(sum([a*a for a in q_vec]))
32         try:
33             sim: float = dot_product / (norm_d * norm_q)
34         except ZeroDivisionError:
35             sim: float = dot_product / ((norm_d * norm_q)+0.0001)
36         sims.append((title, sim))
37
38     return sims
```

تابع **create_document_vectors** با توجه به **tf-idf** های حساب شده در دو تابع قبل بردار داکيومنت ها را می سازد تا در مرحله بعدی شباهت کسینوسی محاسبه شود.

تابع **cosine_similarity** پس از محاسبه بردار کوئری مورد نظر با محاسبه ضرب داخلی بردار ها و اندازه هر بردار شباهت داکيومنت ها به کوئری مورد نظر را محاسبه کرده و درون آرایه **sims** ذخیره می کند تا شباهت همه داکيومنت ها به کوئری را داشته باشیم.


```

1 class Searcher:
2
3     def __init__(self, address_of_documents:str = "./docs/MED.ALL"):
4         self.address_of_documents = address_of_documents
5         self.read_content_from_docs()
6         self.normalize_contents()
7         self.cosineSimilarity = CosineSimilarity(self, information)
8         self.results: List[Tuple[str, int]] = []
9
10    def preprocessed_text(self, text:str )-> str:
11        """This function takes a Text and removes the stop words and finds the root of the rest
12
13        Args:
14            text (str): A string of words in a row
15
16        Returns:
17            str: A string that removed stop words and finds the root of the rest
18        """
19        stopwords: Any = frozenset(stoplists["en"])
20
21        analyzer = StemmingAnalyzer(stemfn=stem, stoplist=stopwords) | StopFilter(stoplist=stopwords)
22        # Tokenize and analyze the text using the defined analyzer
23        tokens:List[str] = [token.text for token in analyzer(text)]
24
25        # Join the tokens back together to form a preprocessed string
26        preprocessed_text = " ".join(tokens)
27
28        return preprocessed_text
29
30    def read_content_from_docs(self, address:str = "./docs/MED.ALL"):
31        """ This func create list of information of each document that each info includes
32            a document number and content
33
34        Args:
35            address (str, optional): " Address of file that content documents". Defaults to "./docs/MED.ALL".
36
37        """
38
39        with open(address, 'r') as file:
40            documents = file.read()
41            list_of_documents = documents.split(".I")[1:]
42            # Create list of document number and content
43            self.information:Any = [[
44                doc.split(".W")[0].replace("\n", "").strip(),
45                doc.split(".W")[1].replace("\n", " ")
46                for doc in list_of_documents
47            ]

```

کلاس Searcher:

تابع اول همانطور که در کد مشاهده می کنید وظیفه نرمال سازی داکيومنت ها را دارد لذا با استفاده از يه سری عملیات همچون **stemming** و ... داکيومنت های مورد نظر را نرمال می کنیم.

تابع دوم وظیفه خواندن از فایل را برعهده دارد که تمام داکيومنت های موجود در پوشه **docs** و فایل **MED.ALL** به صورت پیشفرض خوانده و با فرمت قابل پیمایش ارائه میدهد

```

1 def normalize_contents(self) :
2     """ Normalize content of each document with call preprocessed_text func
3
4     Args:
5         information (List[List[str]]): List of info that each element is a list that contain a document number and content
6
7     Returns:
8         List[List[str]]: A list that removed stop words and finds the root of the rest
9     """
10    for index,info in enumerate(self.information):
11        document_number , content = info[0],info[1]
12        # Update content each info with remove stop words and ...
13        self.information[index] = (document_number,self.preprocessed_text(content))
14
15 def search_query(self, query:str)-> List[Any]:
16     """ This function is to get similar document to a document
17
18     Args:
19         query (str): A text to get similar document
20
21     Returns:
22         List[tuple[str,int]]: results of similar document
23     """
24     query = self.preprocessed_text(query)
25     self.results = self.cosineSimilarity.cosine_similarity(query)
26
27 def get_nlargest_similarity_doc(self, n_first:int) ->List[Tuple[str,int]]:
28     return heapq.nlargest(n_first, self.results, key=lambda x: x[1])
29
30 def print_results(self, n_first = 10)-> None:
31     if self.results != None :
32         n_first_similarity_doc = self.get_nlargest_similarity_doc(n_first)
33         print('----- RESULTS -----')
34         print("      SCORE      ***      DOCUMENT NUMBER")
35         print('-----')
36
37         for index,result in enumerate(n_first_similarity_doc):
38             document_number = result[0]
39             score = index + 1
40             print(f"      {score}      {document_number}")
41     else :
42         print("Please First call search query function")

```

پس از نرمال سازی داکيومنت های
 موجود شباهت کسینوسی هر
 داکيومنت را با کوئری مورد نظر
 حساب کرده و درون آرایه **result**
 ذخیره می کنیم سپس با توجه به
 شباهت بیشتر ۱۰ تای بیشتر از نظر
 شباهت را جدا کرده و در خروجی
 نمایش می دهیم

Please enter your query: the crystalline lens in vertebrates, including humans.

----- RESULTS -----		
SCORE	***	DOCUMENT NUMBER

1		72
2		500
3		965
4		360
5		181
6		171
7		166
8		15
9		513
10		838



```
1 s = Searcher()
2 query = input('Please enter your query: ')
3 s.search_query(query)
4 s.print_results(12)
```

تست و بررسی داکيومنت ها :

برای مثال اگر کوئری زیر را داشته باشیم:

query: the crystalline lens in vertebrates, including humans.

خروجی داکيومنت های مورد نظر نشان می دهد که با بررسی فایل MED.REL صحت شباهت های به دست آمده به درستی برقرار است.